

Introducción a la Regresión Lineal Múltiple

Modelos de Analítica Predictiva



Fundamentos y Ecuación del Modelo

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

Componentes del modelo:

- Y: Variable dependiente (lo que queremos predecir)
- β_0 : Intercepto (valor cuando $X = 0$)
- $X_1, X_2, \dots, X_p$: Variables independientes (predictores)
- $\beta_1, \beta_2, \dots, \beta_p$: Coeficientes de regresión
- ε : Término de error (variabilidad no explicada)

Ejemplo práctico - Precio de casa:

- Tamaño (m²)
- Ubicación
- Antigüedad
- Número de habitaciones

Correlación y Multicolinealidad

Correlación: Fuerza de relación lineal entre variables

- Rango: -1 a +1
- Positiva: Variables aumentan juntas
- Negativa: Una aumenta, otra disminuye

Interpretación de la fuerza:

- 0.0 - 0.1: No hay correlación
- 0.1 - 0.3: Poca correlación
- 0.3 - 0.5: Correlación media
- 0.5 - 0.7: Correlación alta
- 0.7 - 1.0: Correlación muy alta

Ejemplo: Matriz de Correlación

	Edad	Ingresos	Educación
Edad	1.0	0.5	0.3
Ingresos	0.5	1.0	0.8
Educación	0.3	0.8	1.0

- Multicolinealidad: Variables independientes altamente correlacionadas
- VIF (Factor de Inflación):
 - VIF = 1: Sin correlación
 - $1 < \text{VIF} < 5$: Moderada (aceptable)
 - $\text{VIF} > 5$: Problema de multicolinealidad

Análisis de Varianza (ANOVA)

Propósito: Evaluar la significancia global del modelo

- Descomponer la variabilidad total en:
 - Variabilidad explicada por el modelo
 - Variabilidad no explicada (residual)

F-test y Hipótesis:

- $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$ (modelo no es útil)
- H_1 : Al menos un $\beta_k \neq 0$ (modelo es significativo)
- $F = MSR/MSE$

Ejemplo de Tabla ANOVA:

	SS	gl	MS	F	Sig.
Regresión	3650.192	2	1825.096	63.751	0.000
Residual	343.542	12	28.628		
Total	3993.733	14			

Interpretación:

- p-valor = 0.000 < 0.05
- Se rechaza H_0
- El modelo ES significativo

Significancia de Variables Individuales

Prueba t para Coeficientes

Evalua si cada variable es significativa

Hipotesis para cada coeficiente:

H0: Beta = 0 (variable no significativa)

H1: Beta $\neq$ 0 (variable significativa)

Estadistico de prueba:

$$t = \text{Beta} / \text{SE}(\text{Beta})$$

Interpretacion del p-valor

Criterio de decision (alfa = 0.05):

p-valor menor 0.05: Variable significativa

p-valor mayor 0.05: Variable no significativa

Intervalos de Confianza (95%):

$$\text{Beta} \pm t(0.025) * \text{SE}(\text{Beta})$$

Si el intervalo **no incluye 0**, la variable es significativa

Significancia de Variables Individuales

Ejemplo Practico

Modelo: $\text{Precio} = B_0 + B_1(\text{Area}) + B_2(\text{Habitaciones})$

	Coef.	t-stat	p-valor
Area	150.5	8.42	0.000
Habitaciones	-2.1	-0.15	0.882

Conclusiones

Area: $p = 0.000 < 0.05$

SI - Variable significativa

Habitaciones: $p = 0.882 > 0.05$

NO - Variable no significativa

Recomendacion: Considerar eliminar la variable "Habitaciones" del modelo para mejorar la parsimonia.

Ajuste y Selección de Variables

Modelo Completo

- Incluye todas las variables disponibles
- Puede tener variables no significativas
- Riesgo de sobreajuste (overfitting)
- Mayor complejidad de interpretación



Modelo Seleccionado

- Solo variables significativas
- Principio de parsimonia
- Mejor capacidad de generalización
- Más fácil de interpretar

Métodos de Selección

- Eliminación hacia atrás (Backward Elimination)
- Selección hacia adelante (Forward Selection)
- Selección por pasos (Stepwise Selection)

Ejemplo: R^2 ajustado = 0.900
(90% de variabilidad explicada)

Métricas de Evaluación: R^2 y RMSE

R^2 - Coeficiente de Determinación

Definición:

- Proporción de varianza explicada por el modelo
- Rango: 0 a 1
- Más cercano a 1 = mejor explicación

Interpretación práctica:

$R^2 = 0.85$ significa que el 85% de la variación en precios de viviendas se explica por las características del modelo

RMSE - Raíz del Error Cuadrático Medio

Definición:

- Magnitud promedio de errores de predicción
- Expresado en unidades de la variable dependiente
- RMSE menor = mejores predicciones

Interpretación práctica:

RMSE $\sqrt{5,000}$ € significa que las predicciones se desvían en promedio 5,000€ del precio real

Ambas métricas son complementarias para evaluar el rendimiento del modelo

¿Qué define a un 'Buen' Modelo?



1. Significancia Estadística Global

- F-test con p-valor < 0.05
- Variables individuales significativas



2. Cumplimiento de Supuestos

- Linealidad de relaciones
- Independencia de errores
- Homocedasticidad y normalidad



3. Interpretabilidad

- Coeficientes con sentido lógico
- Resultados comprensibles
- Relevancia para el negocio



4. Capacidad de Generalización

- Evita el sobreajuste (overfitting)
- Funciona con datos nuevos
- Validación cruzada exitosa

Nota: Un 'buen' modelo no se define solo por R^2 alto o RMSE bajo, sino por el cumplimiento integral de estos criterios en contexto.

Conclusiones y Aplicación en Python

32 pat /CA4332, 16:9

Puntos Clave de la Regresión Lineal Múltiple:

- Herramienta fundamental para analistas de datos
- Permite predecir y comprender relaciones complejas
- Proceso riguroso: análisis exploratorio → construcción → evaluación
- Selección de variables crucial para resultados confiables
- Métricas como R^2 y RMSE guían hacia modelos robustos

Implementación Práctica en Python:

- Librerías esenciales: statsmodels y scikit-learn
- Transformación de datos en conocimiento valioso
- Aplicación de conceptos teóricos en proyectos reales
- Análisis de correlación, ANOVA y evaluación de modelos



```
import statsmodels.api as sm  
from sklearn.linear_model import  
LinearRegression
```